

DATA & AI WORKSHOP ASSESSMENT

Thammasat University

Data Specification Document

Part 1: Data Discovery and Specification

Scope ของระบบ

In Scope

- Import Excel
- Data Profiling
- Analytics
- Dashboard
- RAG
- Source Citation

Functional Requirements

ตอนนี้ยังไม่ค่อยมีเลย เช่น

ID	Requirement
FR-01	ระบบต้องอ่าน Excel ได้
FR-02	ระบบต้องสร้าง Raw Layer
FR-03	ระบบต้องสร้าง Trusted Layer
FR-04	ระบบต้องตอบคำถามด้วย RAG
FR-05	ระบบต้องแสดง Source Reference

1. Use Case Summary และ Business Context

เอกสารนี้ครอบคลุมหน้าที่ของ Business Analyst ในโปรเจกต์ Thammasat Data & AI Workshop Assessment ซึ่งประกอบด้วย Use Case Definition, Data Specification, Data Dictionary, Business Keys, Source-to-Target Mapping, Column Usage Matrix, Data Profiling, และ Quality Summary Design

ด้าน	รายละเอียด
Business Goal	วิเคราะห์ข้อมูล synthetic นักศึกษา Thammasat เพื่อทำ Data & AI Platform — ครอบคลุม Batch Ingestion, Trusted Analytics, และ RAG Q&A
Data Source	thammasat_workshop_dataset.xlsx — sheet: workshop_data — 180 rows, 49 columns

ด้าน	รายละเอียด
Record Type	student (180 rows — synthetic/mock data ไม่ใช่ข้อมูลนักศึกษาจริง)
Primary Users	Data Analyst, AI Engineer, Data Governance, Instructor / Workshop Reviewer
Key Questions	ใครสนใจสาย Data Engineer / AI? คาดหวังเงินเดือนเท่าไร? มี teamwork style อะไรบ้าง? profile นักศึกษา RAG ตอบได้ไหม?
Data Note	ข้อมูลเป็น synthetic/mock เพื่อการศึกษาเท่านั้น ไม่ใช่ข้อมูลนักศึกษาจริงหรือข้อมูลเงินเดือนทางการ

2. Data Profiling Summary

ผลการ profile ข้อมูลจาก thammasat_workshop_dataset.xlsx — sheet: workshop_data

Dimension	Value	หมายเหตุ
Total Rows	180	record_type = 'student' ทั้งหมด
Total Columns	49	12 columns NULL ทั้งหมด (fact/doc/batch group)
Campus	Rangsit: 144 Tha Phra Chan: 36	80% Rangsit
Level	Undergraduate: 140 Postgraduate: 40	78% UG
Status	Active:161 Leave:6 Exchange:6 Withdrawn:4 Graduated:3	89% Active
Top Career Interest	Data Engineer/AI: 68 (38%) Health Data: 37 (21%) DA/BI: 29 (16%)	6 career categories
GPA	Min: 1.94 Mean: 3.00 Max: 4.00	ไม่มี NULL
Credit Earned	Min: 10 Mean: 64.4 Max: 140	ไม่มี NULL
Expected Salary (THB)	Min: 27,500 Mean: 36,008 Max: 42,500	Mock data
NULL Columns	12 columns (fact_category, metric_or_item, value, unit, year_or_as_of, doc_title, doc_section, doc_text, doc_type, batch_date, required_action, protection_classification)	NULL 100% — ไม่ใช่ใน pipeline

3. Column Group Overview

49 columns แบ่งออกเป็น 8 กลุ่มตามวัตถุประสงค์การใช้งาน

Column Group	จำนวน Columns	ตัวอย่าง Columns
Row Identity / Traceability	3	record_type, entity_id, source_row_no
Student Profile (Synthetic)	5	student_no, citizen_id, email, mobile, student_name
Academic Attributes	10	level, faculty_or_school, program_id, campus, status, gpa, credit_earned, is_international, ...
Behavior / Career Mock-up	6	behavior_profile, teamwork_style, learning_preference, career_interest, internship_interest, mock_interview_note
Salary Mock-up	2	expected_salary_thb, salary_expectation_note
RAG Document Fields	5	rag_document_title, rag_document_text, rag_keywords, rag_sample_question, rag_expected_answer_hint
Operational Metadata	6	batch_date, snapshot_date, source_system, source_url, task_hint, protection_classification
Unused / NULL Columns	12	fact_category, metric_or_item, value, unit, year_or_as_of, doc_title, doc_section, doc_text, doc_type, batch_date, required_action, protection_classification — NULL ทั้งหมด 180 แถว

4. Data Dictionary

สีพื้นหลังแต่ละแถวแสดง Column Group: สีเทา = Identity/Metadata, น้ำเงิน = Profile/RAG, เขียว = Academic, เหลือง = Behavior/Salary, แดง = NULL columns

Column Name	Data Type	Nullable	Business Definition	Column Group
record_type	String	No	ประเภทของ record ค่าในชุดนี้คือ 'student' ทั้งหมด ใช้สำหรับ routing และ filtering	Row Identity
entity_id	String	No	Unique identifier ระดับ entity เช่น SK0001 ใช้เป็น business key หลัก	Row Identity
source_row_no	Integer	No	หมายเลข row ใน source file ใช้สำหรับ traceability, lineage, และ RAG citation	Row Identity
snapshot_date	String (Date)	No	วันที่ snapshot ข้อมูล รูปแบบ YYYY-MM-DD ใช้สำหรับ partition และ audit	Operational Metadata
batch_date	Float/NULL	Yes	วันที่ batch run เป็น Null	Operational Metadata
source_system	String	No	ระบบต้นทาง เช่น synthetic_public_training_extract	Operational Metadata
source_url	String	No	URL อ้างอิง เช่น topuniversities.com ใช้สำหรับ RAG citation	Operational Metadata
task_hint	String	No	คำแนะนำสำหรับ workshop	Operational Metadata

Column Name	Data Type	Nullable	Business Definition	Column Group
student_no	String	No	รหัสนักศึกษา เช่น TU202300001	Student Profile
citizen_id	String	No	เลขบัตรประชาชน ไม่ใช่ข้อมูลจริง	Student Profile
email	String	No	อีเมลนักศึกษา	Student Profile
mobile	String	No	เบอร์โทรศัพท์	Student Profile
student_name	String	No	ชื่อนักศึกษา	Student Profile
level	String	No	ระดับการศึกษา: Undergraduate (140), Postgraduate (40)	Academic
faculty_or_school	String	No	ชื่อคณะ/สำนัก เช่น Faculty of Science and Technology	Academic
program_id	String	No	รหัสหลักสูตร เช่น TU-SCI-UG ใช้สำหรับ grouping และ filter	Academic
program_name	String	No	ชื่อหลักสูตร เช่น Computer Science / Data Science	Academic
discipline_cluster	String	No	กลุ่มสาขา: STEM, Health, Business, Communication, Law, Economics, Social Science, Interdisciplinary	Academic
campus	String	No	วิทยาเขต: Rangsit (144), Tha Phra Chan (36)	Academic
year_of_study	Integer	No	ชั้นปีปัจจุบัน ค่า 1-6 สำหรับ Undergraduate / Postgraduate	Academic
admission_channel	String	No	ช่องทางรับเข้า เช่น TCAS Quota, International Admission	Academic
status	String	No	สถานะนักศึกษา: Active(161), Leave(6), Exchange(6), Withdrawn(4), Graduated(3)	Academic
gpa	Float	No	เกรดเฉลี่ยสะสม min=1.94, mean=3.00, max=4.00	Academic
credit_earned	Integer	No	หน่วยกิตที่ได้รับ min=10, mean=64.4, max=140	Academic
is_international	Boolean	No	นักศึกษาต่างชาติหรือไม่ True/False	Academic
behavior_profile	String	No	ลักษณะนิสัยการทำงาน เช่น Analytical and structured	Behavior/Career
teamwork_style	String	No	รูปแบบการทำงานเป็นทีม 8 รูปแบบ กระจายเท่ากัน 22-23 คนต่อรูปแบบ	Behavior/Career
learning_preference	String	No	วิธีการเรียนที่ชอบ 8 รูปแบบ กระจายเท่ากัน 22-23 คนต่อรูปแบบ	Behavior/Career
career_interest	String	No	สายงานที่สนใจ 6 สาย — Data Engineer/AI(68), Health(37), DA/BI(29), Governance(25), Digital Analytics(15), Data Product(6)	Behavior/Career
internship_interest	String	No	ความสนใจด้าน internship เช่น Business intelligence dashboard	Behavior/Career
mock_interview_note	String	No	บันทึก mock interview synthetic ใช้สำหรับ RAG example	Behavior/Career
expected_salary_thb	Integer	No	เงินเดือนที่คาดหวัง (mock) min=27,500, mean=36,008, max=42,500 THB	Salary Mock-up

Column Name	Data Type	Nullable	Business Definition	Column Group
salary_expectation_note	String	No	หมายเหตุ mock salary — ระบุชัดว่าไม่ใช่ข้อมูลทางการ	Salary Mock-up
rag_document_title	String	No	หัวข้อเอกสาร RAG เช่น 'Student mock profile - Chalisa Panyadee'	RAG Document
rag_document_text	String	No	เนื้อหาหลักสำหรับ RAG corpus — paragraph รายละเอียด student profile ครบถ้วน	RAG Document
rag_keywords	String	No	คำสำคัญสำหรับ keyword search / embedding เช่น faculty, career, campus	RAG Document
rag_sample_question	String	No	ตัวอย่างคำถาม RAG เช่น 'What is X's career interest?'	RAG Document
rag_expected_answer_hint	String	No	คำตอบอ้างอิงสำหรับ evaluate RAG answer grounding	RAG Document

5. Business Keys และ Row Identity

นิยาม key ทุกระดับเพื่อรองรับ deduplication, upsert, traceability, และ RAG citation

Key Type	Column(s)	Scope	วัตถุประสงค์
Primary Business Key	entity_id	Entity level	Unique identifier สำหรับ student entity ใช้สำหรับ deduplication และ upsert
Secondary Key	student_no	Entity level	รหัสนักศึกษา synthetic ใช้ร่วมกับ entity_id สำหรับ join และ analytics
Snapshot Key	entity_id + snapshot_date	Snapshot level	Composite key สำหรับ historical snapshot ป้องกัน duplicate ใน trusted layer
Row Traceability	source_row_no	Row level	ติดตาม row ต้นทางในไฟล์ Excel ใช้สำหรับ RAG citation และ audit
RAG Document Key	source_row_no / entity_id	Document level	ใช้เป็น chunk_id / document_id สำหรับ RAG retrieval และ source citation

6. Technical Metadata (Pipeline-Generated Fields)

Fields เหล่านี้ไม่ได้อยู่ใน source Excel แต่ pipeline จะสร้างเพิ่มเมื่อ load ข้อมูล

Field	Type	คำอธิบาย
load_timestamp	Timestamp	เวลาที่ load row เข้า target layer — สร้างโดย pipeline (ไม่ได้อยู่ใน source)
business_date	Date	วันที่ batch run parameter — ส่งเข้ามาเป็น parameter ไม่ hard-code
run_id	String/UUID	รหัส unique ของแต่ละ batch run เช่น UUID หรือ timestamp-based ID

Field	Type	คำอธิบาย
source_file_name	String	ชื่อไฟล์ต้นทาง เช่น thammasat_workshop_dataset.xlsx
sheet_name	String	ชื่อ sheet ใน Excel เช่น workshop_data
input_file_checksum	String (MD5/SHA256)	Checksum ของไฟล์ input ใช้ตรวจสอบ idempotency — run ซ้ำไฟล์เดิม checksum ต้องตรงกัน
record_status	String	สถานะ record: active, rejected, superseded — ใช้ใน trusted layer

7. Target Layer Naming Convention

นิยามชื่อ table/file สำหรับแต่ละ layer เพื่อให้มีชื่อเดียวกันตลอด pipeline

Layer	Table / File Name	คำอธิบาย
Raw	raw_workshop_data	Raw Excel rows ไม่แตะต้อง + metadata
Staging	stg_student_snapshot	Type-cast, cleaned, validated
Trusted	trusted_student_snapshot	Deduplicated, upserted, business-ready
Analytics	analytics_student_summary	Aggregated view สำหรับ dashboard/report
RAG Corpus	rag_excel_document_chunk	RAG fields + metadata สำหรับ embedding/retrieval
Batch Audit	batch_audit	Run log: run_id, status, counts, timestamps

8. Source-to-Target Mapping

แสดง data flow จาก Excel source ไปยัง trusted layer และ RAG corpus

Source Layer	Target Layer/Table	Transformation	รายละเอียด
Excel File (.xlsx)	raw_workshop_data	None	อ่าน sheet workshop_data ทุก column เก็บ raw โดยไม่แก้ไข + เพิ่ม load_timestamp, run_id, source_file_name
raw_workshop_data	stg_student_snapshot	Type cast	แปลง data types: snapshot_date → Date, gpa → Float, credit_earned/expected_salary_thb → Integer, is_international → Boolean
stg_student_snapshot	trusted_student_snapshot	Dedup + Upsert	Deduplicate โดยใช้ entity_id + snapshot_date เป็น composite key

Source Layer	Target Layer/Table	Transformation	รายละเอียด
trusted_student_snapshot	analytics_student_summary	Aggregate	Summary view: count by campus/level/status/career_interest, GPA stats, salary stats
trusted_student_snapshot	rag_excel_document_chunk	Chunk extract	ดึง RAG fields (rag_document_title, rag_document_text, rag_keywords, ...) + metadata (source_row_no, entity_id, source_url)

9. Column Usage Matrix (Access Classification)

ระบุว่าแต่ละ column group ควรใช้ใน layer ใดบ้าง — สำหรับ workshop นี้ไม่ต้อง mask/hash/encrypt

Column Group	Raw Layer	Analytics	RAG Corpus	Access Level (Workshop)
Row Identity (entity_id, source_row_no)	Yes	Key only	As metadata	All workshop users
Student Profile (name, citizen_id, email...)	Yes (mock)	No	Yes (mock)	Workshop use only
Academic Attributes	Yes	Yes	As metadata	All workshop users
Behavior / Career Mock-up	Yes	Yes (mock)	Yes (mock)	Workshop use
Salary Mock-up	Yes	Yes (mock)	Yes (mock)	Workshop use
RAG Document Fields	Yes	No	Primary corpus	AI Engineer + BA review
NULL Columns (12 columns)	No (skip)	No	No	Exclude — all NULL

หมายเหตุ: สำหรับข้อมูลนักศึกษาจริงในระบบ Production จะต้องมีการ Data Governance ที่เข้มงวดกว่านี้ เช่น masking citizen_id, เซอร์วิสข้อมูลส่วนบุคคล และจำกัดสิทธิ์การเข้าถึง แต่ในขอบเขตของ workshop นี้ใช้ข้อมูล synthetic ได้โดยตรง

10. Data Quality Summary Design

รายการ quality checks ที่ pipeline ควรทำ เพื่อเปรียบเทียบ source vs target และหยุด/flag เมื่อพบความผิดพลาด

Quality Check	Source (Excel)	Target Expected	Action if Fail
Total row count	180	180	Stop pipeline — investigate
record_type = 'student'	180	180	Flag unknown record_type
Rangsit campus count	144	144	Flag — recheck source

Quality Check	Source (Excel)	Target Expected	Action if Fail
Tha Phra Chan count	36	36	Flag — recheck source
GPA min / max	1.94 / 4.00	1.94 / 4.00	Flag out-of-range values
expected_salary_thb min / max	27,500 / 42,500	27,500 / 42,500	Flag — label as mock data
credit_earned min / max	10 / 140	10 / 140	Flag negative values
NULL count (fact_category, batch_date etc.)	180 each	Skip columns	Exclude from pipeline — expected

11. RAG Business Questions (BA-Defined)

Business Analyst กำหนดคำถามที่ผู้ใช้งานจะถาม เพื่อให้ AI Engineer ออกแบบ RAG pipeline ได้ถูกต้อง

Sample Business Question	Expected RAG Grounding
ใครสนใจสาย Data Engineer / AI Engineer บ้าง?	career_interest = 'Data Engineer / AI Engineer' 68 คน
ช่วง expected salary mock ของนักศึกษาอยู่ที่เท่าไร?	min=27,500 / mean=36,008 / max=42,500 THB
มี teamwork style อะไรบ้าง ในชุดข้อมูลนี้?	8 รูปแบบแต่ละแบบ ~22-23 คน
นักศึกษา entity SK0001 มี behavior profile อะไร?	Analytical and structured; validates assumptions before deciding
ถ้าถามเรื่องที่ไม่มีในไฟล์ ระบบควรตอบอย่างไร?	ตอบ 'Not found in workbook' ไม่ hallucinate

12. Assumptions และ Limitations

Assumptions

- ข้อมูลทั้งหมดเป็น synthetic/mock ไม่ใช่ข้อมูลนักศึกษา Thammasat จริง
- ไม่มีการ mask, hash, หรือ encrypt columns ใดๆ ในขอบเขตของ workshop นี้
- 12 columns ที่ NULL ทั้งหมด (fact_category, metric_or_item, value, unit, year_or_as_of, doc_title, doc_section, doc_text, doc_type, batch_date, required_action, protection_classification) จะถูก exclude จาก pipeline
- expected_salary_thb เป็น mock data — ต้อง label ชัดเจนทุกครั้งที่แสดงใน analytics หรือ RAG
- RAG corpus ใช้ rag_document_text เป็น primary field — ทุก row มีค่า

Limitations

- ไม่มี historical snapshot data — snapshot_date เดียวกันทั้งหมด (2026-06-28)
- ไม่มี faculty/program dimension table แยก — ข้อมูลอยู่ใน flat structure เท่านั้น
- batch_date เป็น NULL ทั้งหมด — ไม่สามารถใช้ partition by batch_date ได้
- 12 columns ที่ NULL อาจมีข้อมูลใน dataset version อื่น — ควร document ไว้

